

Limpieza y consolidación de bases CNA y CN

López Mathias Joel.

Contents

Introducción	1
Carga de librerías	1
1. Carga y limpieza del Censo Nacional (CN) 2010 – NBI	2
2. Censo Nacional Agropecuario 2009 (CNA)	2
3. Censo Nacional Agropecuario 2018 (CNA)	4
4. Unión de CNA + CN + población por provincia	4
5. Creación de variables derivadas	5
Exportar base final	6

Introducción

Este documento tiene como objetivo consolidar los datos de explotaciones agropecuarias (EAP) de hortalizas y frutales por provincia a partir de los censos agropecuarios de 2008 y 2018 (CNA), y los datos de Necesidades Básicas Insatisfechas (NBI) del Censo Nacional 2010. A lo largo del procesamiento se realizaron:

- Carga masiva de archivos Excel y CSV
- Selección de hojas y filas específicas
- Limpieza y transformación de variables
- Unificación en un único data.frame
- Creación de variables nuevas a partir de los datos crudos

Carga de librerías

```
library(tidyverse)
library(janitor)
library(readxl)
library(dplyr)
library(purrr)
library(stringr)
```

1. Carga y limpieza del Censo Nacional (CN) 2010 – NBI

```
NBI_Prov <- read_excel("C:/Anlisis-consumo-frutihorticola-Arg/Procesamiento y preparacion de datos/1. D
# Seleccionamos columnas y eliminamos filas vacías
NBI_Prov <- NBI_Prov %>%
  select(Provincia, ...4, ...7) %>%
  na.omit()
```

```
cn_nbi <- NBI_Prov %>%
  select(Provincia, ...4, ...7) %>%
  rename(
    porcentaje_hogares_nbi = ...4,
    porcentaje_población_nbi = ...7
  ) %>%
  filter(!Provincia %in% c("Total del país", "24 partidos del Gran Buenos Aires", "Interior de la provi
  clean_names()

# Replicamos la info para los 3 años de ENFR
cn_nbi <- tidyr::crossing(cn_nbi, ano_edicion = c(2009, 2013, 2018)) %>%
  mutate(ano_edicion = as.character(ano_edicion)) %>%
  arrange(ano_edicion)

# Renombramos provincias para que coincidan con otras bases
cn_nbi <- cn_nbi %>%
  mutate(
    provincia = ifelse(provincia == "Tierra del Fuego, Antártida e Islas del Atlántico Sur", "Tierra de
    provincia = ifelse(provincia == "Ciudad Autónoma de Buenos Aires", "CABA", provincia)
  )
```

2. Censo Nacional Agropecuario 2009 (CNA)

Los datos del CNA 2009 están estructurados por más de un archivo y cada uno contiene los datos de cada provincia en una hoja específica. En primera instancia se exploró el archivo perteneciente a la provincia de Buenos Aires para ver cómo estaba estructurado el dataset, y luego se procedió a automatizar el proceso.

Automatización para todas las provincias

```
# 2.1. Listar los archivos en la carpeta

## Se listan todos los archivos .xls en la carpeta indicada. El orden coincide con el orden de las prov.
```

```

archivos <- list.files("C:/Anlisis-consumo-frutihorticola-Arg/Procesamiento y preparacion de datos/1. D

## Función para buscar la hoja que contiene los datos a usar ("cuadro 3.2", sin importar mayúsculas)

buscar_hoja <- function(archivo) {
  sheets <- excel_sheets(archivo)
  match <- sheets[which(str_detect(tolower(sheets), "cuadro 3\\.2"))]
  if (length(match) == 0) return(NA) else return(match[1])
}

## 2.2. crear tabla con rutas y provincias
### Creamos un data.frame llamado metadata que contiene:
### la ruta a cada archivo,
### el nombre de la hoja donde se encuentran los datos,
### el nombre real de la provincia.

tabla_rutas <- tibble(
  archivo = archivos,
  hoja = map_chr(archivos, buscar_hoja),
  provincia = c(
    "Buenos Aires", "Catamarca", "Chaco", "Chubut", "Cordoba", "Corrientes", "Entre Rios", "Formosa", "Jujuy",
    "Misiones", "Neuquen", "Rio Negro", "Salta", "San Juan", "San Luis", "Santa Cruz", "Santa Fe", "Santiago de

## 2.3. Función para procesar cada archivo

### La siguiente función se encarga de:
### leer el archivo Excel y la hoja correspondiente,
### extraer la fila 4 (con totales),
### seleccionar las columnas "Hortalizas" y "Frutales",
### redondear y agregar el nombre de la provincia.

procesar_archivo <- function(archivo, hoja, provincia) {
  read_excel(archivo, sheet = hoja, skip = 3) %>%
    slice(4) %>%
    select(Hortalizas, Frutales) %>%
    rename(
      grupo_hortalizas_ha = Hortalizas,
      grupo_frutales_ha = Frutales
    ) %>%
    mutate(
      across(c(grupo_hortalizas_ha, grupo_frutales_ha), ~ round(as.numeric(.x), 2)),
      provincia = provincia
    )
}

## 2.4. Mapear sobre todos los archivos

### Aplicamos la función a todos los archivos utilizando pmap_dfr(), lo que nos permite recorrer fila p

cna_09 <- pmap_dfr(tabla_rutas, procesar_archivo) %>%
  mutate(ano_edicion = "2009")

```

3. Censo Nacional Agropecuario 2018 (CNA)

```
data <- read.csv("C:/Anlisis-consumo-frutihorticola-Arg/Procesamiento y preparacion de datos/1. Datos b

cna_18 <- data %>%
  filter(PERODO.DE.OCUPACION == "Total", PROVINCIA != "País") %>%
  select(PROVINCIA, GRUPO.DE.CULTIVOS.ORTALIZAS, GRUPO.DE.CULTIVOS.FRUTALES) %>%
  rename(
    provincia = PROVINCIA,
    grupo_hortalizas_ha = GRUPO.DE.CULTIVOS.ORTALIZAS,
    grupo_frutales_ha = GRUPO.DE.CULTIVOS.FRUTALES
  ) %>%
  mutate(ano_edicion = "2018") %>%
  clean_names()

### Nos quedamos solamente con fila "total" del periodo, ya que es la suma de todos los periodos y elim

# Conversión de coma decimal a punto
convertor <- function(x) {
  x <- gsub("\\.", "", x)
  x <- gsub(",", ".", x)
  as.numeric(x)
}

cna_18 <- cna_18 %>%
  mutate(
    grupo_hortalizas_ha = convertor(grupo_hortalizas_ha),
    grupo_frutales_ha = convertor(grupo_frutales_ha)
  )
```

4. Unión de CNA + CN + población por provincia

```
cna_09_18 <- bind_rows(cna_09, cna_18)

CNA_CN_limpia <- cn_nbi %>%
  left_join(cna_09_18, by = c("ano_edicion", "provincia"))
```

Agregamos población por provincia:

```
poblacion_prov_09 <- data.frame(
  provincia = c("Buenos Aires", "CABA", "Tierra del Fuego", "Misiones", "Cordoba",
    "Catamarca", "Formosa", "Rio Negro", "Jujuy", "Tucuman", "San Juan", "Corrientes",
    "Salta", "Chaco", "San Luis", "Neuquen", "La Rioja", "Mendoza", "Chubut",
    "Santa Fe", "Santiago del Estero", "Santa Cruz", "Entre Rios", "La Pampa"),
  num_habitantes = c(14917940, 3034161, 122531, 1061590, 3311280, 380612, 532238, 594189, 670766, 14573
    1002416, 1202753, 1042881, 428025, 538952, 334235, 1711416, 455607, 3220818, 856739, 22
  ano_edicion = "2009"
)
```

```

# str(poblacion_prov_09)

poblacion_prov_18 <- data.frame(
  provincia = c("Buenos Aires", "CABA", "Tierra del Fuego", "Misiones", "Cordoba",
    "Catamarca", "Formosa", "Rio Negro", "Jujuy", "Tucuman", "San Juan", "Corrientes",
    "Salta", "Chaco", "San Luis", "Neuquen", "La Rioja", "Mendoza", "Chubut",
    "Santa Fe", "Santiago del Estero", "Santa Cruz", "Entre Rios", "La Pampa"),
  num_habitantes = c(16841135, 3059122, 156509, 1204182, 3606540, 400678, 584614, 708799, 736542, 16134,
    482796, 628897, 372879, 1907045, 577466, 3425656, 938109, 329499, 329499, 346191 ),
  ano_edicion = "2018"
)

# str(enfr_2009$rango_edad)

poblacion_prov_total <- bind_rows(poblacion_prov_09, poblacion_prov_18)

CNA_CN_limpia <- CNA_CN_limpia %>%
  left_join(poblacion_prov_total, by = c("ano_edicion", "provincia"))

```

5. Creación de variables derivadas

```

# Factorizamos la variable Año de Edición
CNA_CN_limpia$ano_edicion <- factor(CNA_CN_limpia$ano_edicion,
  levels = c("2009", "2013", "2018"))

# Variable porcentaje de hogares con NBI por jurisdiccion
CNA_CN_limpia <- CNA_CN_limpia %>%
  group_by(ano_edicion) %>%
  mutate(
    nbi_provincial_ter = cut(
      porcentaje_hogares_nbi,
      breaks = quantile(porcentaje_hogares_nbi, probs = c(0, 1/3, 2/3, 1), na.rm = TRUE),
      labels = c("Bajo", "Medio", "Alto"),
      include.lowest = TRUE) %>%
    ungroup()

# Variable EAP frutihorticola
CNA_CN_limpia <- CNA_CN_limpia %>%
  mutate( eap_frutihorticola_num = (grupo_hortalizas_ha + grupo_frutales_ha))

# Transformacion a terciles
CNA_CN_limpia <- CNA_CN_limpia %>%
  filter(!is.na(eap_frutihorticola_num)) %>%
  group_by(ano_edicion) %>%
  mutate(
    eap_frutihorticola_ter = if (all(is.na(eap_frutihorticola_num))) {
      NA
    }
  )

```

```

    } else {
      cut(
        eap_frutihorticola_num,
        breaks = quantile(eap_frutihorticola_num, probs = c(0, 1/3, 2/3, 1), na.rm = TRUE),
        labels = c("Bajo", "Medio", "Alto"),
        include.lowest = TRUE
      )
    }
  ) %>%
  ungroup()

# Variable Ha/numero de habitantes y Ha/10 000 de habitantes
CNA_CN_limpia <- CNA_CN_limpia %>%
  mutate(
    hort_x_habitantes = grupo_hortalizas_ha / num_habitantes,
    frut_x_habitantes = grupo_frutales_ha / num_habitantes,
    hort_x_10mil_habitantes = hort_x_habitantes * 10000,
    frut_x_10mil_habitantes = frut_x_habitantes * 10000
  )

## Reordenamos la base de datos final
CNA_CN_limpia <- CNA_CN_limpia %>%
  select(ano_edicion, provincia, eap_frutihorticola_ter, grupo_hortalizas_ha, grupo_frutales_ha, hort_x_habitantes,
    frut_x_habitantes, hort_x_10mil_habitantes, frut_x_10mil_habitantes, porcentaje_hogares_nbi, n)

```

Exportar base final

```

write.csv(CNA_CN_limpia, "C:/Anlisis-consumo-frutihorticola-Arg/Procesamiento y preparacion de datos/2.
saveRDS(CNA_CN_limpia, "C:/Anlisis-consumo-frutihorticola-Arg/Procesamiento y preparacion de datos/2. P

```