

Limpieza y recodificación de las bases ENFR (2009, 2013, 2018)

López Mathias Joel.

Introducción

Este archivo tiene como objetivo realizar la carga, selección, recodificación y unificación de las bases de datos de la Encuesta Nacional de Factores de Riesgo (ENFR) correspondientes a los años 2009, 2013 y 2018. Se construyen variables relevantes para el análisis posterior, como nivel de instrucción, quintil de ingresos, cumplimiento de recomendaciones de consumo de frutas y verduras y un índice dicotómico de NBI a nivel de hogar.

Librerías

```
library(tidyverse)
library(dplyr)
library(purrr)
library(janitor)
```

Carga y limpieza de bases ENFR

ENFR 2009

```
data1 <- read.table("C:/Anlisis-consumo-frutihorticola-Arg/Procesamiento y preparacion de datos/1. Datos
enfr_2009 <- data1 %>%
  select(PRVNC, REGION, ITF_UC_QUINTILES, BHCH04, BHCH05, RANGEDAD, NIVINSTR, PROMEDIO_FV_DIARIO, BHCVO
  rename(provincia = PRVNC,
         quintil_ingresos = ITF_UC_QUINTILES,
         genero = BHCH04,
         edad = BHCH05,
         rango_edad = RANGEDAD,
         nivel_de_instruccion = NIVINSTR,
         promedio_fyv_dia = PROMEDIO_FV_DIARIO) %>%
  mutate(ano_edicion = "2009") %>%
  clean_names()
```

ENFR 2013

```
data2 <- read.table("C:/Anlisis-consumo-frutihorticola-Arg/Procesamiento y preparacion de datos/1. Datos

enfr_2013 <- data2 %>%
  select(COD_PROVINCIA, ITF_UC_QUINTILES, BHCH04, BHCH05, RANGO_EDAD, NIVEL_INSTRUCCION, PROMEDIO_FV_DI
  rename(provincia = COD_PROVINCIA,
         quintil_ingresos = ITF_UC_QUINTILES,
         genero = BHCH04,
         edad = BHCH05,
         eango_edad = RANGO_EDAD, # Posible error de tipeo
         nivel_de_instruccion = NIVEL_INSTRUCCION,
         promedio_fyv_dia = PROMEDIO_FV_DIARIO) %>%
  mutate(ano_edicion = "2013") %>%
  clean_names()
```

ENFR 2018

```
data3 <- read.table("C:/Anlisis-consumo-frutihorticola-Arg/Procesamiento y preparacion de datos/1. Datos

enfr_2018 <- data3 %>%
  select(cod_provincia, quintil_uc, bhch03, bhch04, rango_edad, nivel_instruccion, promedio_fv_diario, l
  rename(provincia = cod_provincia,
         quintil_ingresos = quintil_uc,
         genero = bhch03,
         edad = bhch04,
         rango_edad = rango_edad,
         nivel_de_instruccion = nivel_instruccion,
         promedio_fyv_dia = promedio_fv_diario) %>%
  mutate(ano_edicion = "2018")

enfr_2018$promedio_fyv_dia <- as.numeric(enfr_2018$promedio_fyv_dia)
```

Estandarización de variables

Antes de JOINEAR las BD se verifica si alguna de las variables tiene alguna categoria/rango/grupo con una codificacion diferente.

```
## Chequeo de diferencias en la nomenclatura de las categorias variables

lista_base <- list(enfr_2009 = enfr_2009, enfr_2013 = enfr_2013, enfr_2018 = enfr_2018)

for (i in names(lista_base)){
  nombres <- lista_base[[i]]
  print(i)
  for (x in names(nombres)){
    if(!(x %in% c("promedio_fyv_dia", "edad", "ingresos_mes_hogar"))){
      print(x)
      print(unique(nombres[[x]]))
    }
  }
}
```

```
}
}
```

Ajuste de codificación rango_edad en ENFR 2009

```
enfr_2009 <- enfr_2009 %>%
  mutate(rango_edad = case_when(
    rango_edad == 2 ~ 1,
    rango_edad == 3 ~ 2,
    rango_edad == 4 ~ 3,
    rango_edad == 5 ~ 4,
    rango_edad == 6 ~ 5
  ))
```

Unificación de las tres encuestas

```
enfr_total <- bind_rows(enfr_2009, enfr_2013, enfr_2018)
```

Recodificación de variables

```
# Provincia
enfr_total <- enfr_total %>%
  mutate(provincia = case_when(
    provincia == 2 ~ "CABA",
    provincia == 6 ~ "Buenos Aires",
    provincia == 10 ~ "Catamarca",
    provincia == 22 ~ "Chaco",
    provincia == 26 ~ "Chubut",
    provincia == 14 ~ "Cordoba",
    provincia == 18 ~ "Corrientes",
    provincia == 30 ~ "Entre Rios",
    provincia == 34 ~ "Formosa",
    provincia == 38 ~ "Jujuy",
    provincia == 42 ~ "La Pampa",
    provincia == 46 ~ "La Rioja",
    provincia == 50 ~ "Mendoza",
    provincia == 54 ~ "Misiones",
    provincia == 58 ~ "Neuquen",
    provincia == 62 ~ "Rio Negro",
    provincia == 66 ~ "Salta",
    provincia == 70 ~ "San Juan",
    provincia == 74 ~ "San Luis",
    provincia == 78 ~ "Santa Cruz",
    provincia == 82 ~ "Santa Fe",
    provincia == 86 ~ "Santiago del Estero",
    provincia == 90 ~ "Tucuman",
```

```

    provincia == 94 ~ "Tierra del Fuego"
  ))

# Género
enfr_total <- enfr_total %>%
  mutate(genero = case_when(
    genero == 1 ~ "Varon",
    genero == 2 ~ "Mujer"
  ))

# Nivel de instrucción
enfr_total <- enfr_total %>%
  filter(nivel_de_instruccion != 8) %>%
  mutate(nivel_de_instruccion = case_when(
    nivel_de_instruccion %in% 1:3 ~ "Primario",
    nivel_de_instruccion %in% 4:5 ~ "Secundario",
    nivel_de_instruccion %in% 6:7 ~ "Terc/Univ"
  ))

# Quintil de ingreso
enfr_total <- enfr_total %>%
  filter(!is.na(quintil_ingresos)) %>%
  mutate(quintil_ingresos = as.character(quintil_ingresos))

# Rango edad
enfr_total <- enfr_total %>%
  mutate(rango_edad = as.character(rango_edad))

```

Creacion de la variable respuesta

```

# Consumo de frutas y verduras
enfr_total <- enfr_total %>%
  filter(!is.na(promedio_fyv_dia)) %>%
  mutate(cumple_nocumple = ifelse(promedio_fyv_dia >= 3, "Cumple", "No_cumple"))

```

Construcción del índice compuesto de NBI

```

enfr_total <- enfr_total %>%
  mutate(
    tipo_vivienda = ifelse(bhcv01 %in% c("1", "3"), 0, 1),
    tipo_suelo = ifelse(bhcv03 %in% c("1", "2"), 0, 1),
    tipo_cocina = ifelse(bhcv06 %in% c("1", "2"), 0, 1),
    tipo_baño = ifelse(bhcv09 == "1", 0, 1),
    tipo_agua = ifelse(bhcv08 %in% c("1", "2"), 0, 1)
  )

# Hacinamiento
enfr_total <- enfr_total %>% filter(bhcv02 != "99")

```

```

enfr_total <-enfr_total %>%
  mutate(condicion1 = bhcv02 == 1,
         condicion1b = cant_componentes <= 3,
         condicion2 = bhcv02 == 2,
         condicion2b = cant_componentes <= 6,
         condicion3 = bhcv02 == 3,
         condicion3b = cant_componentes <= 9,
         condicion4 = bhcv02 == 4,
         condicion4b = cant_componentes <= 12,
         condicion5 = bhcv02 == 5,
         condicion5b = cant_componentes <= 15,
         condicion6 = bhcv02 == 6,
         condicion6b = cant_componentes <= 18,
         condicion7 = bhcv02 == 7,
         condicion7b = cant_componentes <= 21,
         condicion8 = bhcv02 == 8,
         condicion8b = cant_componentes <= 24,
         condicion9 = bhcv02 == 9,
         condicion9b = cant_componentes <= 27,
         condicion10 = bhcv02 == 10,
         condicion10b = cant_componentes <= 30,
         condicion11 = bhcv02 == 11,
         condicion11b = cant_componentes <= 33,
         condicion12 = bhcv02 == 12,
         condicion12b = cant_componentes <= 36,
         tipo_hacinamiento = ifelse((condicion1 & condicion1b) |
                                   (condicion2 & condicion2b) |
                                   (condicion3 & condicion3b) |
                                   (condicion4 & condicion4b) |
                                   (condicion5 & condicion5b) |
                                   (condicion6 & condicion6b) |
                                   (condicion7 & condicion7b) |
                                   (condicion8 & condicion8b) |
                                   (condicion9 & condicion9b) |
                                   (condicion10 & condicion10b) |
                                   (condicion11 & condicion11b) |
                                   (condicion12 & condicion12b), 0, 1))

# Índice NBI dicotómico
enfr_total <- enfr_total %>%
  mutate(sum_tipos = tipo_vivienda + tipo_suelo + tipo_cocina +
         tipo_baño + tipo_agua + tipo_hacinamiento,
         indice_nbi_hogar_dic = as.numeric(sum_tipos >= 1))

```

Armado de base fina

```

ENFR_limpia <- enfr_total %>%
  select(ano_edicion, provincia, cumple_nocumple, genero, edad, rango_edad, nivel_de_instruccion, quint

```

Validación

```
ENFR_limpia %>% group_by(ano_edicion) %>% summarise(n = n())
```

```
## # A tibble: 3 x 2
##   ano_edicion      n
##   <chr>         <int>
## 1 2009          34186
## 2 2013          31857
## 3 2018          28424
```

```
colSums(is.na(ENFR_limpia))
```

```
##      ano_edicion      provincia      cumple_nocumple
##      0              0              0
##      genero          edad          rango_edad
##      0              0              31857
## nivel_de_instruccion quintil_ingresos indice_nbi_hogar_dic
##      0              0              0
##      promedio_fyv_dia      region
##      0              60281
```

```
summary(ENFR_limpia)
```

```
##  ano_edicion      provincia      cumple_nocumple      genero
## Length:94467      Length:94467      Length:94467      Length:94467
## Class :character  Class :character  Class :character  Class :character
## Mode  :character  Mode  :character  Mode  :character  Mode  :character
##
##
##
##      edad      rango_edad      nivel_de_instruccion quintil_ingresos
## Min.   : 18.00      Length:94467      Length:94467      Length:94467
## 1st Qu.: 30.00      Class :character  Class :character  Class :character
## Median : 42.00      Mode  :character  Mode  :character  Mode  :character
## Mean   : 45.21
## 3rd Qu.: 59.00
## Max.   :104.00
##
## indice_nbi_hogar_dic promedio_fyv_dia      region
## Min.   :0.00000      Min.   : 0.000      Min.   :1.00
## 1st Qu.:0.00000      1st Qu.: 1.000      1st Qu.:2.00
## Median :0.00000      Median : 1.571      Median :3.00
## Mean   :0.07451      Mean   : 1.979      Mean   :3.36
## 3rd Qu.:0.00000      3rd Qu.: 2.571      3rd Qu.:5.00
## Max.   :1.00000      Max.   :48.000      Max.   :6.00
##
##                                     NA's      :60281
```

Exportación

```
write_csv(ENFR_limpia, "C:/Anlisis-consumo-frutihorticola-Arg/Procesamiento y preparacion de datos/2. Pro  
saveRDS(ENFR_limpia, "C:/Anlisis-consumo-frutihorticola-Arg/Procesamiento y preparacion de datos/2. Pro
```